


Logistic Regression

⇒ 분류 (classification) 알고리즘

= (이진 분류 : Binary Classification) 의 예


Tumor size vs Malignancy (0 or 1)



위의 경우로 학습이 되었다면

linear regression 을 적용하여도
잘 작동이 된다.

그러나 만약 학습 sample 이 아래와 같다면,
linear regression 은 성능이 매우 저하된다.




즉 Malignant 인데도 Benign 으로 잘못 분류 될수도.

아래 같은 문제를 해결하기 위하여
 모든 예측 값들이 0과 1 사이로 존재하게끔
 linear 함수를 logistic (= sigmoid) 함수로
 mapping을 (치환을) 하면 좋다.


(참고) Sigmoid function = logistic function

$$g(z) = 1 / (1 + e^{-z})$$



(치환 쪽 매핑을 하면) 즉 $z = w^T x$ 라고

$$g(z) = \frac{1}{1 + e^{w^T x}}$$



(Decision Boundary)

(안아두기) Sigmoid function을 활용하면
positive ($z \geq 0$) 와 negative ($z < 0$)의
구분이 매우 쉽다.

따라서


$y=1$ 은 $g(z)$ 의 z 가 0보다
크기 때문으로 $W^T X \geq 0$ 을 만족하면 되고,

$y=0$ 은 $g(z)$ 의 z 가 0보다
작은 것이므로 $W^T X < 0$ 이면 된다.

(예)

feature 2개, \dots 로 이루어진
모델

$$\hat{y}(z) = g(b + w_1 x_1 + w_2 x_2)$$



• ~~max~~

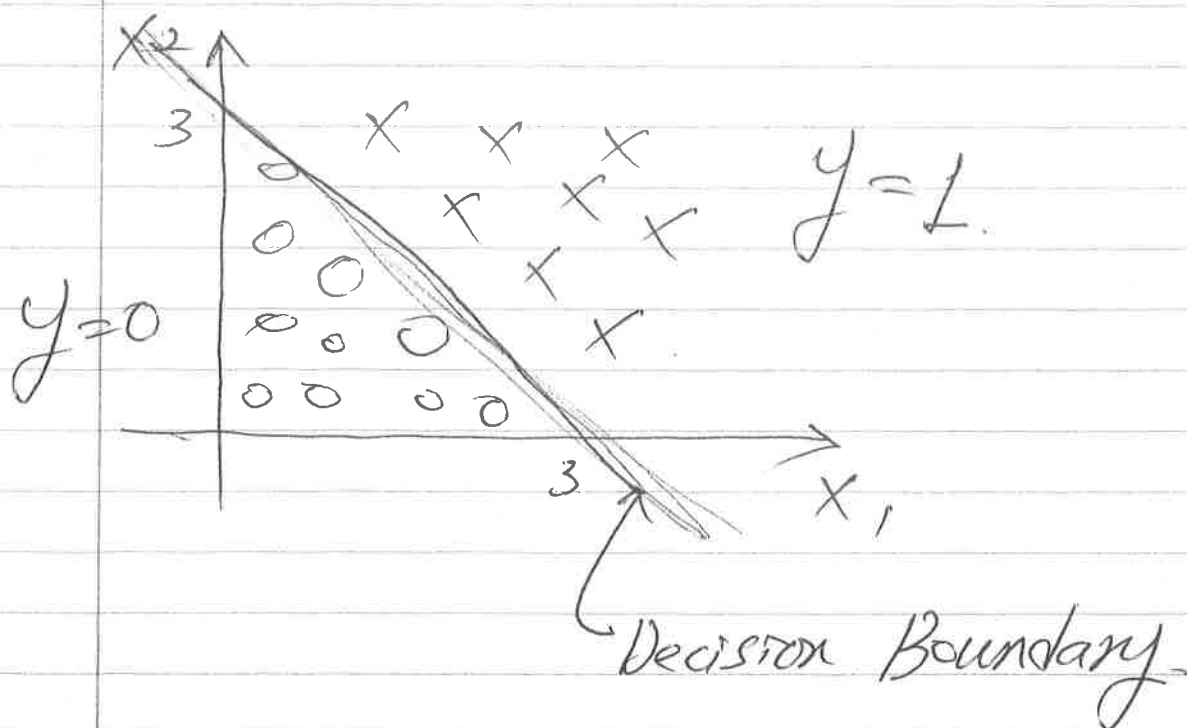
$$b = -3$$

$$w_1 = 1$$


$$w_2 = 1$$

0/34 3/1021

$$\left[\begin{array}{ll} -3 + x_1 + x_2 \geq 0 & \Rightarrow y=1 \\ -3 + x_1 + x_2 < 0 & \Rightarrow y=0 \end{array} \right]$$



Non-linear Decision Boundaries



$$\hat{y} = b + w_1 x_1 + w_2 x_2 + w_3 x_1^2 + w_4 x_2^2 \quad \text{or}$$


$$g(z) = g(b + w_1 x_1 + w_2 x_2 + w_3 x_1^2 + w_4 x_2^2) \quad \text{or}$$

여기서 $b = -1, w_1 = 0, w_2 = 0, w_3 = 1, w_4 = 1$

이라 가정하면


$$\begin{cases} -1 + x_1^2 + x_2^2 \geq 0 & y=1 \end{cases}$$

$$\begin{cases} -1 + x_1^2 + x_2^2 < 0 & y=0 \end{cases}$$



Cost function for Logistic Regression

반대 $y=1$ 이면




$g(z)$ 가 1에 가까워지면
 $y=1$ 일 확률이
 높으므로 cost는
 0에 가까워지고,
 $g(z)$ 가 0에 가까워
 지면 $y=1$ 일
 확률이 작아지므로
 cost는 무한대로
 커진다.

$$0 < g(z) < 1 \text{ 범위}$$

$\Rightarrow y=1$ 이면 logistic regression

모델의 cost는 $g(z)$ 가 1에 가까워지면
 0에 수렴하고 $g(z)$ 가 0에 가까워지면
 무한대로 커지는 cost function을
 갖는다.

$$\text{수학적으로 } \text{cost}(g(z), y) = -\log(g(z))$$



위와 반대로 $g(z)$ 가 0에 가까우면
 $y=0$ 이 될 확률이 높으므로 cost는
 0에 가까워지고, $g(z)$ 가 1에
 가까워지면 $y=0$ 일 확률은 낮아지므로
 cost는 극한대로 커진다.

수학적으로

$$\text{cost}(g(z), y) = -\log(1 - g(z))$$

앞의 두개의 cost function은
합쳐서

$$\text{cost}(g(z), y) = \begin{cases} -\log(g(z)) & , y=1 \\ -\log(1-g(z)) & , y=0 \end{cases}$$

$$\Rightarrow = -y \log(g(z)) - (1-y) \log(1-g(z))$$

* $z = w^T x$ $g(z) = \frac{1}{1 + e^{-w^T x}}$

\Rightarrow linear regression 은
logistic (sigmoid) function on
mapping 이

Logistic Regression Model

Support Vector Machines (SVMs)


logistic Regression model의 cost function을
fully expand 하라.

Cost function

$$= -(y \log(g(z)) + (1-y) \log(1-g(z)))$$

$$= -y \log \frac{1}{1+e^{-z}} - (1-y) \log \left(1 - \frac{1}{1+e^{-z}}\right)$$

⊗ 여기서 $z = W^T X$ 이고 W 는 학습된 가중치
(linear regression이라 가정하라)



만약 z 가 충분히 크다면


즉 $\hat{y} = w^T x$ 가 충분히 크다면

비용은 충분히 낮아지므로 문제가 없고,

만약 z 가 작아진다면

즉 $\hat{y} = w^T x$ 가 음수의 영향이면,

모델의 cost는 매우 커질 것이다.




반대로 $y=0$ 이면

z 가 커지면 비용이 증가하고

z 가 작아지면 비용이 감소한다.

⑧ SVM cost functions from logistic Regression cost functions.

① if $y = 1$.



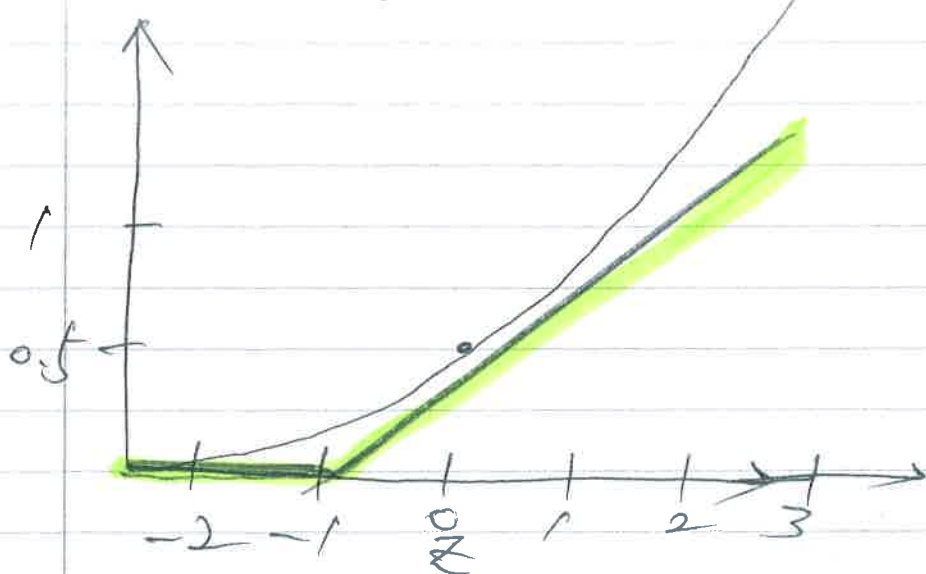
두개의 라인을 만들어 cost function을
조금 더 강건하게 만들면

최적화 및 계산상의 이점을 취할 수 있다.



이를 $y=1$ 일때 cost function을
사용하라는 concept이
SVM 이다.

② if $y = 0$ 이면



비슷한 노력으로 $y = 0$ 이면



같은 cost function을 사용
하라는 concept이
SVM 이다.

⑤ 이런 비용함수

제곱 힌지 (Squared Hinge)

손실 함수라 함.

• (Regularization 이해하기.)

① linear regression 이서는

$$\text{cost} = \text{MSE} + \lambda B \quad (\text{여기서 } B = \sum_{i=1}^n w_i^2)$$

이 cost 를 minimize 하는 것으로

regularization을 함으로 λ 가 커지면

규제를 많이하고 λ 가 작아지면

규제를 적게하는 것으로 이해를 하였다.

② 그러나 Logistic Regression과
SVMs 의 경우는

$C = 1/\lambda$ 이라는 매개변수를 사용하여

규제를 함으로 C 가 커지면 규제를

적게하고 C 가 작으면 규제를 많이함.

$$\min_w C \sum_{i=1}^m [\text{비용 함수}] + \frac{\lambda}{2} w_i^2 \text{ 이항함.}$$